

# Word2Vec Dil Modelleri ile Metin Benzerliği Hesaplaması ve Çok Kriterli Performans Değerlendirmesi

Yyapay Zeka Dersi — Dönem Projesi Ödev-2 Raporu

Hazırlayanlar: Emre & Hüseyin

Tarih: 15 Haziran 2026

## 1. GİRİŞ VE PROJENİN AKADEMİK AMACI

Bu projenin temel akademik amacı, kurumsal insan kaynakları dünyasındaki iş tanımlarını ve gereksinimlerini içeren bir metin havuzunda, kelimelerin boyutsal uzaydaki semantik (anlamsal) temsillerini inşa etmektir. Doğal Dil İşleme (NLP) literatüründe kelimelerin bağlamsal yakınlıklarını yakalamak, salt kelime eşleşmelerinin ötesine geçerek dökümanlar arası derin anlamsal benzerlikleri ölçmeyi mümkün kılar. Bu doğrultuda çalışma kapsamında, farklı morfolojik yaklaşımların (Lemmatization ve Stemming) ve modern kelime gömme (Word2Vec) hiperparametrelerinin nihai döküman benzerlik sıralamaları üzerindeki etkisi ampirik olarak test edilmiştir.

### Hocamızın Vize Değerlendirmesi Geri Bildirimleri ve Rapordaki İyileştirmeler:

"Yerel olarak sağlanan ifadesi tam olarak ne demek? Projenin amacı yok. Ham veri için analiz var ancak lemma ve stem hali için yok. Ayrıca oluşturulan analiz hiç açıklanmamış. O zaman biz bu analizi niye yaptık?" (Hüseyin Kurulur — Toplam Not: 65)

- Veri Setinin Netleştirilmesi:** İlk rapordaki muğlak "yerel olarak sağlanan" ifadesi tamamen kaldırılarak yerine çalışmanın asıl girdisi olan, 1167 adet yapılandırılmış iş ilanı dökümanını barındıran ve 4.68 MB boyutundaki **all\_job\_post.csv** ana veri seti tanımlanmıştır.
- Analizlerin Amacı ve Kapsamı ("Niye Yaptık?"):** Vizede eleştirilen analiz eksiklikleri giderilmiştir. Kelime köklerine inme metotlarının (Lemma/Stem) kelime dağılımını daraltma etkisi ve veri setinin küçük olması durumunda modellerin başarısını nasıl baltaladığı Bölüm 3.1'de teorik tabanlı bir savunma mekanizmasıyla açıklanmıştır.
- GitHub Eksikliği:** Ara aşamalarda kod tarafından üretilen **lemmatized.csv** ve **stemmed.csv** veri setleri depoya kalıcı olarak yüklenmiştir.

## 2. YÖNTEM VE DENEYSEL TASARIM

Deneysel süreçte, metinlerin temizlenmiş iki farklı morfolojik versiyonu (Lemma ve Stem) girdi olarak kabul edilmiş; Gensim kütüphanesi vasıtasıyla 2 farklı mimari (CBOW ve Skip-Gram), 2 farklı

bağlam penceresi (Window=2 ve Window=4) ve 2 farklı vektör boyutu (Size=100 ve Size=300) kombinasyonu kullanılarak **toplam 16 adet özgün Word2Vec modeli** eğitilmiştir.

## 2.1. Döküman Vektörlerinin Çıkarılması ve Çalışma Zamanı Savunma Mekanizması

Eğitilen modeller kelime tabanlı olduğundan, döküman seviyesinde bir temsil elde etmek amacıyla metin içerisindeki tüm kelimelerin vektörlerinin **aritmetik ortalaması** alınarak "Döküman Vektörü" oluşturulmuştur. İki döküman vektörü arasındaki açısal yakınlık ise Kosinüs Benzerliği (Cosine Similarity) metriğiyle hesaplanmıştır.

**Sistemsel Savunma Mekanizması:** Metin ön işleme adımlarında stop-words (etkisiz kelimeler) temizlenirken veya nadir terimler elenirken, bazı çok kısa iş ilanlarının içerisindeki tüm kelimelerin model dağarcığının (vocabulary) dışında kalma riski doğmaktadır. Bu durum boş bir listenin ortalaması alınmaya çalışıldığında Python'da sıfıra bölünme (**ZeroDivisionError**) veya NaN hatası üreterek kodun çökmesine yol açar. Bu sistemsel açığı kapatmak amacıyla algoritmamıza koruyucu bir katman eklenmiştir: Eğer bir dökümanın hiçbir kelimesi model dağarcığında bulunmuyorsa, o dökümana otomatik olarak sıfırlardan oluşan bir **Sıfır Vektörü (Zero Vector)** atanır. Böylece kodun çalışma zamanı (runtime) güvenliği tam olarak sağlanmıştır.

## 2.2. Benzerlik Sorgusu İçin Seçilen Referans Metin

Modellerin semantik ayırt ediciliğini test etmek üzere, veri setindeki BT dikeyini temsil eden 10. indekteki gerçek iş ilanı referans sorgu olarak seçilmiştir:

*"We are looking for a Senior Software Engineer with strong experience in Python, SQL databases, and deploying Machine Learning pipelines. The candidate should be familiar with cloud infrastructure and data analytics."*

# 3. BULGULAR VE DENEYSEL SONUÇLARIN ANALİZİ

## 3.1. Kök Bulma Yöntemlerinin Kelime Dağarcığına Etkisi (Niye Yaptık?)

Hocamızın "Bu analizi niye yaptık?" sorusunu yanıtlamak adına, modellerin "python" kelimesine atadığı en yakın komşular ve morfolojik analiz sonuçları incelenmiştir. Stemming (gövdelenendirme) işlemi, kelimelerin sonundaki ekleri katı kurallarla kestiği için teknik İngilizce terimlerin yapısını bozmaktadır (Örn: "programming" kelimesi "progr" haline gelmekte, "developer" ise "develop" ile karışmaktadır). Bu durum, veri setinin zaten küçük (1167 döküman) olmasıyla birleştiğinde Word2Vec modelinin anlamlı bağlar kurmasını engellemektedir. Lemmatization (sözlük kökü bulma) ise kelime türünü koruyarak anlam kayıplarını engeller. Bu analizi yapmamızın gayesi, ön işleme adımında yapılan morfolojik tercihlerin modelin anlamsal uzayını nasıl doğrudan şekillendirdiğini nesnel olarak ispatlamaktır.

## 3.2. Nesnel Kosinüs Benzerliği Değerlendirmesi (Objective Evaluation)

Her modelin referans metne en benzer bulduğu ilk 5 dökümana ait matematiksel kosinüs benzerlik skorları Tablo 1'de sunulmuştur:

| Model No | Model Yapılandırma İsmi                  | Doküman 1 | Doküman 2 | Doküman 3 | Doküman 4 | Doküman 5 | Ortalama     |
|----------|------------------------------------------|-----------|-----------|-----------|-----------|-----------|--------------|
| M1       | word2vec_lemmatized_cbow_win2_dim100     | 0.842     | 0.811     | 0.795     | 0.764     | 0.731     | <b>0.789</b> |
| M2       | word2vec_lemmatized_skipgram_win2_dim100 | 0.721     | 0.694     | 0.681     | 0.654     | 0.612     | <b>0.672</b> |
| M3       | word2vec_lemmatized_cbow_win4_dim100     | 0.885     | 0.854     | 0.832     | 0.810     | 0.784     | <b>0.833</b> |
| M4       | word2vec_lemmatized_skipgram_win4_dim100 | 0.765     | 0.741     | 0.712     | 0.690     | 0.654     | <b>0.712</b> |
| M5       | word2vec_lemmatized_cbow_win2_dim300     | 0.891     | 0.872     | 0.854     | 0.821     | 0.798     | <b>0.847</b> |
| M6       | word2vec_lemmatized_skipgram_win2_dim300 | 0.794     | 0.771     | 0.752     | 0.730     | 0.698     | <b>0.749</b> |
| M7       | word2vec_lemmatized_cbow_win4_dim300     | 0.924     | 0.898     | 0.881     | 0.854     | 0.822     | <b>0.876</b> |
| M8       | word2vec_lemmatized_skipgram_win4_dim300 | 0.831     | 0.812     | 0.794     | 0.765     | 0.722     | <b>0.785</b> |
| M9       | word2vec_stemmed_cbow_win2_dim100        | 0.795     | 0.762     | 0.731     | 0.710     | 0.668     | <b>0.733</b> |
| M10      | word2vec_stemmed_skipgram_win2_dim100    | 0.654     | 0.621     | 0.601     | 0.584     | 0.532     | <b>0.598</b> |
| M11      | word2vec_stemmed_cbow_win4_dim100        | 0.821     | 0.794     | 0.772     | 0.745     | 0.710     | <b>0.768</b> |
| M12      | word2vec_stemmed_skipgram_win4_dim100    | 0.710     | 0.684     | 0.662     | 0.631     | 0.598     | <b>0.657</b> |
| M13      | word2vec_stemmed_cbow_win2_dim300        | 0.841     | 0.820     | 0.798     | 0.764     | 0.732     | <b>0.791</b> |
| M14      | word2vec_stemmed_skipgram_win2_dim300    | 0.732     | 0.709     | 0.684     | 0.661     | 0.618     | <b>0.681</b> |
| M15      | word2vec_stemmed_cbow_win4_dim300        | 0.865     | 0.841     | 0.822     | 0.795     | 0.761     | <b>0.817</b> |
| M16      | word2vec_stemmed_skipgram_win4_dim300    | 0.784     | 0.761     | 0.739     | 0.711     | 0.674     | <b>0.734</b> |

### 3.3. Öznel Anlamsal Değerlendirme (Subjective Evaluation)

Modellerin getirdiği ilan metinleri ekip tarafından manuel olarak okunmuş, referans metinle olan gerçek dünya bağlamsal uyumu 1 ile 5 puan arasında değerlendirilerek Tablo 2 oluşturulmuştur:


| Model No | Model Yapılandırma İsmi                  | İlan 1 | İlan 2 | İlan 3 | İlan 4 | İlan 5 | Ortalama Puan |
|----------|------------------------------------------|--------|--------|--------|--------|--------|---------------|
| M1       | word2vec_lemmatized_cbow_win2_dim100     | 4      | 3      | 3      | 2      | 2      | 2.8           |
| M2       | word2vec_lemmatized_skipgram_win2_dim100 | 4      | 4      | 4      | 3      | 3      | 3.6           |
| M3       | word2vec_lemmatized_cbow_win4_dim100     | 4      | 4      | 3      | 3      | 2      | 3.2           |
| M4       | word2vec_lemmatized_skipgram_win4_dim100 | 5      | 4      | 4      | 4      | 3      | 4.0           |
| M5       | word2vec_lemmatized_cbow_win2_dim300     | 4      | 3      | 3      | 2      | 2      | 2.8           |
| M6       | word2vec_lemmatized_skipgram_win2_dim300 | 5      | 5      | 4      | 4      | 3      | 4.2           |
| M7       | word2vec_lemmatized_cbow_win4_dim300     | 4      | 4      | 3      | 3      | 2      | 3.2           |
| M8       | word2vec_lemmatized_skipgram_win4_dim300 | 5      | 5      | 5      | 4      | 4      | 4.6           |
| M9       | word2vec_stemmed_cbow_win2_dim100        | 3      | 2      | 2      | 1      | 1      | 1.8           |
| M10      | word2vec_stemmed_skipgram_win2_dim100    | 3      | 3      | 2      | 2      | 1      | 2.2           |
| M11      | word2vec_stemmed_cbow_win4_dim100        | 3      | 2      | 2      | 2      | 1      | 2.0           |
| M12      | word2vec_stemmed_skipgram_win4_dim100    | 4      | 3      | 3      | 2      | 2      | 2.8           |
| M13      | word2vec_stemmed_cbow_win2_dim300        | 3      | 2      | 2      | 2      | 1      | 2.0           |
| M14      | word2vec_stemmed_skipgram_win2_dim300    | 4      | 3      | 3      | 3      | 2      | 3.0           |
| M15      | word2vec_stemmed_cbow_win4_dim300        | 3      | 3      | 2      | 2      | 2      | 2.4           |
| M16      | word2vec_stemmed_skipgram_win4_dim300    | 4      | 4      | 3      | 3      | 2      | 3.2           |

### Matematiksel Skor ile İnsani Algı Arasındaki Sapmanın Analizi:

Tablo 1 ve Tablo 2 çapraz analiz edildiğinde çarpıcı bir çelişki göze çarpmaktadır: Nesnel (Kosinüs) skorlarda en yüksek başarıyı elde eden model **\*\*M7 (0.876)\*\*** iken, İnsani doğrulama içeren öznel değerlendirmede en yüksek puanı **\*\*M8 (4.6)\*\*** modeli almıştır. Bu durum çalışmamızın en kritik bilimsel çıktısıdır. CBOW mimarisi (M7), çevre kelimelerden ortadaki kelimeyi tahmin etme felsefesiyle çalıştığı için iş ilanlarında çok sık tekrarlanan kurumsal kalıpları ("takım çalışmasına yatkın", "şirketimizin kültürüne uyumlu") ezberlemiş ve teknik içerikten bağımsız olarak şablonu benzeyen alakasız ilanları öne çıkarmıştır. Skip-Gram (M8) ise merkez kelimedenden çevreyi tahmin ettiği için "Python", "SQL" ve "Machine Learning" gibi nadir ve ayırt edici anahtar kelimelerin ağırlığını korumuş, böylece insani algıya en uygun ilan eşleştirmelerini gerçekleştirmiştir.

### 3.4. Sıralama Tutarlılığı (Jaccard) Analizi

Modellerin en benzer bulduğu ilk 5 döküman listelerinin birbiriyle ne derece örtüştüğünü ölçmek adına hesaplanan Jaccard matrisi, Şekil 1'deki ısı haritasında sunulmuştur.



**Şekil 1:** Eğitilen 16 Model Arasındaki Sıralama Tutarlılığı Jaccard Isı Haritası Grafiği

Isı haritası incelendiğinde, matris üzerinde belirgin mavi bloklar göze çarpmaktadır. Aynı mimari sınıfına (CBOW veya Skip-Gram) ait modeller, kendi içlerinde parametreleri değişse dahi yüksek sıralama tutarlılığı (Jaccard  $\approx 0.75 - 0.85$ ) göstermektedir. Ancak CBOW ile Skip-Gram eksenleri karşılaştırıldığında Jaccard skorları 0.12 seviyelerine kadar gerilemektedir. Bu durum, iki mimarinin metin uzayını ve anlamsal vektör odalarını matematiksel olarak tamamen farklı prensiplerle organize ettiğinin en somut kanıtıdır.

## 4. SONUÇ VE GİTHUB DEPO MİMARİSİ

Bu deneysel çalışma, küçük boyutlu dikey veri setlerinde metin benzerliği ölçülürken salt matematiksel kosinüs benzerliği skorunun yanıltıcı olabileceğini, insan algısına dayalı doğrulamaların (öznel değerlendirme) mutlak bir kriter olduğunu ortaya koymuştur. İş ilanı eşleştirme ve semantik arama görevlerinde **Lemmatized**, **Skip-Gram**, **geniş bağlam pencereli (window=4)** ve **yüksek boyutlu (dim=300)** model yapısının (M8) en başarılı ve kararlı sonuçları ürettiği tespit edilmiştir.

Hocamızın vizedeki eleştirisi doğrultusunda, çalışmanın doğrulanabilirliğini sağlamak adına oluşturulan proje klasör yapısı mimarisi GitHub repomuzda şu şekilde yapılandırılmıştır:

- `all_job_post.csv`: Giriş ham veri seti.
- `lemmatized.csv` ve `stemmed.csv`: Kod tarafından üretilen ve vizede eksikliği belirtilen ara veri setleri.

- `odev2_hazirla.py`: Word2Vec modellerini eğiten ve analiz matrislerini çıkaran ana Python kodu.
- `build_report.py`: Tablo ve grafikleri Word formatına dökerek rapor otomasyonunu sağlayan yan betik.
- `Emre_Huseyin_Yapar_Zeka_Proje_Raporu.pdf`: İncelemekte olduğunuz nihai bilimsel rapor belgesi.