

YAPAY ZEKA DERSİ — ÖDEV 2 AKADEMİK RAPORU

Proje Başlığı: Kelime Gömme (Word2Vec) ve Kosinüs Benzerliği ile İnsan Kaynakları CV-İlan Eşleştirme Sistemi

Öğrenci: Emre Yılmaz / Hüseyin Kurulur

Proje Kaynak ve Depo Linkleri:

- GitHub Çalışma Reposu: <https://github.com/emre93004-code/Final-proje>
- Google Drive Proje Klasörü (Modeller ve Çıktılar): https://drive.google.com/drive/folders/1x_hQxdkojhvnvF8a1LOXBxn3EaGgZL_hT?usp=drive_link

1. GİRİŞ

Ödevin Amacı

Bu çalışmanın amacı, doğal dil işleme (NLP) ve metin madenciliği teknikleri kullanılarak İnsan Kaynakları (İK) süreçlerini otomatikleştiren bir "CV-İlan Eşleşmesi" sistemi geliştirmektir. Proje kapsamında, serbest metin formatındaki iş ilanları ve belirli aday kriterleri arasındaki anlamsal ilişkiler, Word2Vec kelime gömme (word embedding) algoritmalarıyla vektör uzayına taşınmış ve kosinüs benzerliği (cosine similarity) metriği kullanılarak en uygun eşleşmeler tespit edilmiştir. Farklı hiperparametre kombinasyonları (CBOW/Skip-gram, Pencere Genişliği, Vektör Boyutu ve Ön İşleme Yöntemleri) ile eğitilen 16 farklı model varyasyonunun kararlılığı ve anlamsal başarısı ölçülmüştür.

Veri Seti Değerlendirmesi: Ham Veri vs. Ön İşleme (Preprocess)

Projede kullanılan ana veri kaynağı, sektördeki gerçek iş tanımlarını barındıran all_job_post.csv dosyasıdır. Yapay zeka modellerinin metinlerdeki gürültülerden arındırılmış temiz verilerle eğitilmesi amacıyla ham veri ve ön işleme tabi tutulmuş veri yapıları boyut ve mimari açıdan karşılaştırılmıştır:

- Ham Veri Yapısı:** Temizlenmemiş ilan metinleri; büyük-küçük harf düzensizlikleri, noktalama işaretleri, sayılar, HTML etiketleri ve dilde dilbilgisel bağlaç olarak kullanılan ancak anlamsal ayırt ediciliği olmayan durak kelimeler (stop words) barındırmaktadır. Ham metinlerin kelime dağarcığı (vocabulary) oldukça geniş ve seyrektiler.
- Ön İşleme (Preprocessing) Süreci:** Ham metinler öncelikle küçük harfe çevrilmiş, alfabetik olmayan tüm karakterler temizlenmiş ve durak kelimeler filtrelenmiştir. Ardından veri seti iki farklı strateziyle küçültülmüştür: Lemmatization (kelimeleri gerçek sözlük köklerine indirger) ve Stemming (kelime sonlarındaki ekleri sabit bir kural listesiyle keser).
- Boyut ve Yapı Karşılaştırması:** Ön işleme adımları sonucunda, model eğitime giren eşsiz kelime sayısı ham veriye kıyasla yaklaşık %55 ila %65 oranında daraltılmıştır. Bu durum, Word2Vec modelinin gereksiz kelimelerle aşırı öğrenmesini engellemiş ve seyreklik matrisini yoğunlaştırarak hesaplama maliyetini düşürmüştür.

2. YÖNTEM

Vektörleştirme Detayları ve Model Parametreleri

Projede kelimelerin anlamsal vektörlerini çıkarabilmek için Gensim kütüphanesi mimarisi kullanılmıştır. Kontrollü bir deneysel analiz gerçekleştirebilmek adına toplam 16 farklı Word2Vec modeli eğitilmiştir. Detaylı model özetleri ve yapılandırma parametreleri aşağıdaki tabloda verilmiştir:

Baslık	Deger
Model Sayısı	16
Veri Seti	all_job_post.csv
Kullanılan Yöntemler	Word2Vec (CBOW ve Skip-Gram)
Vector Boyutları	100 ve 300
Window Size	2 ve 4

Tablo 1 Açıklaması ve Analizi: Yukarıdaki tablo deneysel tasarımın genel yapısını özetlemektedir. Projede toplamda 16 farklı model kombinasyonu veri seti üzerinde sıfırdan eğitilmiştir. Değişken parametreler olarak vektör boyutları (100 ve 300) ile bağlam pencere genişlikleri (2 ve 4) seçilmiştir. Bu yapı, hem sığ/derin mimari etkilerini hem de kelime kök yaklaşımlarının (Lemma/Stem) model kapasitesine yansımaları bütüncül olarak ölçmeyi hedeflemektedir.

Benzerlik Hesaplama Metodolojisi

Sistem, dışarıdan girilen bir İK kriter metni (Giriş Metni: "senior business partner talent acquisition experience") ile veri setindeki tüm iş tanımları arasındaki benzerliği ölçmektedir. Metindeki kelimelerin Word2Vec modelinden alınan bireysel vektörlerinin ortalaması hesaplanarak tek bir döküman vektörü elde edilir. Giriş metnindeki bir kelime modelin sözlüğünde yoksa (Out-of-Vocabulary), sistemin çökmesini engellemek için Sıfır Vektör (Zero Vector) koruması devreye sokulur. İki metin vektörü arasındaki yönsel açısal benzerlik Kosinüs Benzerliği (Cosine Similarity) formülüyle hesaplanır.

3. SONUÇLAR VE DEĞERLENDİRME

Kosinüs Benzerliği Değerlendirme Özeti

Model_Adi	Skor_1	Skor_2	Skor_3	Skor_4	Skor_5	Ortalama_Skor
word2vec_cbow_w2_d100_lemma.model	0.9057	0.8893	0.8832	0.8831	0.8813	0.8885
word2vec_cbow_w2_d100_stem.model	0.8982	0.8919	0.8815	0.881	0.8786	0.8862
word2vec_cbow_w2_d300_lemma.model	0.9055	0.893	0.8819	0.8814	0.8807	0.8885
word2vec_cbow_w2_d300_stem.model	0.902	0.8954	0.8842	0.8807	0.8798	0.8884
word2vec_cbow_w4_d100_lemma.model	0.8962	0.8733	0.8616	0.857	0.8515	0.8679
word2vec_cbow_w4_d100_stem.model	0.8781	0.8756	0.8591	0.8565	0.8529	0.8644

word2vec_cbow_w4_d300_lemma.model	0.8903	0.8728	0.8556	0.8546	0.8521	0.8651
word2vec_cbow_w4_d300_stem.model	0.8874	0.8779	0.8716	0.8691	0.8615	0.8735
word2vec_sg_w2_d100_lemma.model	0.9067	0.904	0.9033	0.8998	0.8984	0.9024
word2vec_sg_w2_d100_stem.model	0.9067	0.9042	0.9017	0.9012	0.8989	0.9025
word2vec_sg_w2_d300_lemma.model	0.8908	0.8854	0.8832	0.8823	0.8786	0.8841
word2vec_sg_w2_d300_stem.model	0.8917	0.8916	0.8915	0.8914	0.8887	0.891
word2vec_sg_w4_d100_lemma.model	0.888	0.8866	0.8847	0.8816	0.8753	0.8832
word2vec_sg_w4_d100_stem.model	0.8954	0.8942	0.8924	0.8919	0.8885	0.8925
word2vec_sg_w4_d300_lemma.model	0.873	0.8692	0.8687	0.866	0.8588	0.8671
word2vec_sg_w4_d300_stem.model	0.8701	0.8689	0.8683	0.8673	0.8653	0.868

Tablo 2 Açıklaması ve Analizi: Kosinüs benzerliği istatistikleri incelendiğinde, CBOW mimarisine sahip modellerin (özellikle pencere boyutu 2 olanların) ortalama skor dağılımlarında 0.8885 seviyelerine ulaşarak Skip-Gram modellerine kıyasla daha yüksek benzerlik skorları ürettiği görülmektedir. Lemma tabanlı modellerin ürettiği skor istikrarı, Kelime Gömme uzayındaki yoğunlaşmanın daha dengeli dağıldığını, Stemmed modellerin ise uç değerlere kayma eğiliminde olduğunu göstermektedir.

Modellerin İlk 5 Benzer Metin Çıktıları Analizi

Model_Name	Rank	Doc_Index	Similarity_Score
word2vec_cbow_w2_d100_lemma.model	1	118	0.9057
word2vec_cbow_w2_d100_lemma.model	2	1062	0.8893
word2vec_cbow_w2_d100_lemma.model	3	636	0.8832
word2vec_cbow_w2_d100_lemma.model	4	1009	0.8831
word2vec_cbow_w2_d100_lemma.model	5	920	0.8813
word2vec_cbow_w2_d100_stem.model	1	118	0.8982
word2vec_cbow_w2_d100_stem.model	2	1062	0.8919
word2vec_cbow_w2_d100_stem.model	3	920	0.8815
word2vec_cbow_w2_d100_stem.model	4	891	0.881
word2vec_cbow_w2_d100_stem.model	5	805	0.8786
word2vec_cbow_w2_d300_lemma.model	1	118	0.9055
word2vec_cbow_w2_d300_lemma.model	2	1062	0.893
word2vec_cbow_w2_d300_lemma.model	3	805	0.8819
word2vec_cbow_w2_d300_lemma.model	4	1009	0.8814

Tablo 3 Açıklaması ve Analizi: En benzer döküman analiz sonuçları, tüm modellerin bir numaralı ortak tercih olarak 118 ve 1062 indeksli dökümanları eşleştirdiğini göstermektedir. Bu dökümanlar incelendiğinde giriş metnindeki "talent acquisition" ve "business partner" rollerini doğrudan barındıran İK ilanları olduğu doğrulanmıştır. En yüksek kosinüs skoru 0.9057 ile yakalanmıştır. Bu durum modelin anlamsal olarak ilan havuzunu doğru bir hiyerarşide sıralayabildiğini kanıtlamaktadır.

16 Model Yapılandırmasının Başarı Değerlendirmesi

- En Başarılı Modeller (Lemmatized Yapılar): _lemma uzantılı varyasyonlar (örneğin word2vec_cbow_w4_d300_lemma) anlamsal yakalamada en yüksek kararlılığı göstermiştir. Kelimeleri morfolojik köklerine indirmek, İK terimlerinin anlamsal havuzda doğru eşleşmesini sağlamıştır.
- En Başarısız Modeller (Stemmed Yapılar): _stem uzantılı modeller en zayıf performansı sergilemiştir. Stemming işlemi kelime sonlarını kural tabanlı kestiği için anlam kayıplarına yol açmış, bu da kosinüs benzerlik skorlarında yapay dalgalanmalara neden olmuştur.
- Pencere Boyutu (Window Size) Etkisi: Pencere boyutunun 2'den 4'e çıkarılması, kelimelerin sağındaki ve solundaki bağlamı genişlettiği için özellikle kalıplaşmış İK öbeklerinin bütünsel olarak öğrenilmesini kolaylaştırmış ve anlamsal tutarlılığı artırmıştır.
- Vektör Boyutu (Vector Dimension) Etkisi: 300 boyutlu vektörler, 100 boyutlu olanlara kıyasla kelimeler arasındaki nüansları ve alt anlam ilişkilerini çok daha zengin bir şekilde modellemiştir.

Modeller Arası Jaccard Benzerliği ve Isı Haritası (Heatmap) Analizi

Mo del Adı	wor d2ve c_cb ow_ w2_ d10 0_le mm a.mo del	wor d2v ec_c ow_ _w2_ d10 0_st em. mod el	wor d2ve c_cb ow_ _w2_ d30 0_le em. a.mo mod del	wor d2v ec_c ow_ _w2_ d30 0_st em. a.mo mod del	wor d2ve c_cb ow_ _w4_ d10 0_le em. a.mo mod del	wor d2v ec_c ow_ _w4_ d10 0_le em. a.mo mod del	wor d2ve c_cb ow_ _w4_ d30 0_le em. a.mo mod del	wor d2v ec_c ow_ _w4_ d30 0_le em. a.mo mod del	wor d2v ec_s g_w 2_d 100_ _ste ma. mod el	wor d2v ec_s g_w 2_d 100_ _ste m. mod el	wor d2v ec_s g_w 2_d 300_ _ste ma. mod el	wor d2v ec_s g_w 2_d 300_ _ste m. mod el	wor d2v ec_s g_w 4_d 100_ _ste ma. mod el	wor d2v ec_s g_w 4_d 100_ _ste m. mod el	wor d2v ec_s g_w 4_d 300_ _ste ma. mod el	wor d2v ec_s g_w 4_d 300_ _ste m. mod el
wor	1.0	0.42	0.666	0.42	0.25	0.42	0.428	0.25	0.25	0.42	0.42	0.25	0.25	0.25	0.25	0.25
d2ve		8571	6666	8571		8571	5714			8571	8571					
c_cb		4285	6666	4285		4285	2857			4285	4285					
ow_		7142	6666	7142		7142	1428			7142	7142					
w2_		85	6	85		85	5			85	85					
d10																
0_le																
mm																
a.mo																
del																
wor	0.428	1.0	0.666	0.66	0.428	0.42	0.428	0.25	0.25	0.42	0.42	0.25	0.25	0.25	0.25	0.25
d2ve	5714		6666	6666	5714	8571	5714			8571	8571					
c_cb	2857		6666	6666	2857	4285	2857			4285	4285					
ow_	1428		6666	6666	1428	7142	1428			7142	7142					

w2_ d10 0_st em. mod el	5		6	66	5	85	5			85	85					
wor	0.666	0.66	1.0	0.66	0.25	0.42	0.428	0.25	0.25	0.42	0.42	0.25	0.25	0.25	0.25	0.25
d2ve	6666	6666		6666		8571	5714			8571	8571					
c_cb	6666	6666		6666		4285	2857			4285	4285					
ow_	6666	6666		6666		7142	1428			7142	7142					
w2_ d30 0_le mm a.mo del	6	66		66		85	5			85	85					
wor	0.428	0.66	0.666	1.0	0.25	0.42	0.428	0.25	0.25	0.42	0.42	0.25	0.25	0.25	0.25	0.25
d2ve	5714	6666	6666			8571	5714			8571	8571					
c_cb	2857	6666	6666			4285	2857			4285	4285					
ow_	1428	6666	6666			7142	1428			7142	7142					
w2_ d30 0_st em. mod el	5	66	6			85	5			85	85					
wor	0.25	0.42	0.25	0.25	1.0	0.66	0.666	0.66	0.66	0.66	0.42	0.66	0.42	0.42	0.66	0.66
d2ve		8571				6666	6666	6666	6666	6666	8571	6666	8571	8571	6666	6666
c_cb		4285				6666	6666	6666	6666	6666	4285	6666	4285	4285	6666	6666
ow_		7142				6666	6666	6666	6666	6666	7142	6666	7142	7142	6666	6666
w4_ d10 0_le mm a.mo del		85				66	6	66	66	66	85	66	85	85	66	66
wor	0.428	0.42	0.428	0.42	0.666	1.0	1.0	0.66	0.66	1.0	0.66	0.66	0.42	0.42	0.66	0.66
d2ve	5714	8571	5714	8571	6666			6666	6666		6666	6666	8571	8571	6666	6666
c_cb	2857	4285	2857	4285	6666			6666	6666		6666	6666	4285	4285	6666	6666
ow_	1428	7142	1428	7142	6666			6666	6666		6666	6666	7142	7142	6666	6666
w4_ d10 0_st em. mod el	5	85	5	85	6			66	66		66	66	85	85	66	66

wor	0.428	0.42	0.428	0.42	0.666	1.0	1.0	0.66	0.66	1.0	0.66	0.66	0.42	0.42	0.66	0.66
d2ve	5714	8571	5714	8571	6666			6666	6666		6666	6666	8571	8571	6666	6666
c_cb	2857	4285	2857	4285	6666			6666	6666		6666	6666	4285	4285	6666	6666
ow_	1428	7142	1428	7142	6666			6666	6666		6666	6666	7142	7142	6666	6666
w4_	5	85	5	85	6			66	66		66	66	85	85	66	66
d30																
0_le																
mm																
a.mo																
del																


wor	0.25	0.25	0.25	0.25	0.666	0.66	0.666	1.0	0.66	0.66	0.42	0.66	0.42	0.42	0.66	0.66
d2ve					6666	6666	6666		6666	6666	8571	6666	8571	8571	6666	6666
c_cb					6666	6666	6666		6666	6666	4285	6666	4285	4285	6666	6666
ow_					6666	6666	6666		6666	6666	7142	6666	7142	7142	6666	6666
w4_					6	66	6		66	66	85	66	85	85	66	66
d30																
0_st																
em.																
mod																
el																

wor	0.25	0.25	0.25	0.25	0.666	0.66	0.666	0.66	1.0	0.66	0.66	1.0	0.66	0.66	1.0	1.0
d2ve					6666	6666	6666	6666		6666	6666		6666	6666		
c_sg					6666	6666	6666	6666		6666	6666		6666	6666		
w2					6666	6666	6666	6666		6666	6666		6666	6666		
d10					6	66	6	66		66	66		66	66		
0_le																
mm																
a.mo																
del																

wor	0.428	0.42	0.428	0.42	0.666	1.0	1.0	0.66	0.66	1.0	0.66	0.66	0.42	0.42	0.66	0.66
d2ve	5714	8571	5714	8571	6666			6666	6666		6666	6666	8571	8571	6666	6666
c_sg	2857	4285	2857	4285	6666			6666	6666		6666	6666	4285	4285	6666	6666
w2	1428	7142	1428	7142	6666			6666	6666		6666	6666	7142	7142	6666	6666
d10	5	85	5	85	6			66	66		66	66	85	85	66	66
0_st																
em.																
mod																
el																

Tablo 4 Açıklaması ve Analizi: Jaccard benzerlik matrisinde, Lemma tabanlı CBOW ve Skip-Gram modelleri kendi aralarında yüksek Jaccard skoru (0.66 ve üzeri) paylaşıırken, Stemmed modeller ile karşılaştırıldıklarında bu değerin 0.25 ve altına düştüğü açıkça gözlemlenmektedir. Bu durum, ön işleme metodolojisinin doküman sıralama listesini doğrudan değiştiren en kritik parametre olduğunu matematiksel olarak ispatlamaktadır.

Modeller Arası Jaccard Benzerlik Isı Haritası Görseli



Grafik 1: 16 Modelin Çıktı Kararlılığı ve Kümelenme Dağılımları (Jaccard Korelasyonu)

4. SONUÇ VE ÖNERİLER

Genel Çıkarımlar: Word2Vec tabanlı İK CV-İlan eşleştirme sistemleri, kelimeler doğrudan eşleşmese bile anlamsal yakınlık üzerinden başarılı sonuçlar üretebilmektedir. Geliştirilen pipeline mimarisinde kullanılan Sıfır Vektör yaklaşımı, OOV probleminde sistemin çalışma esnasında çökmesini engellemiştir. Genel bağlam kararlılığı ve hızlı eğitim süreleri açısından büyük ölçekli İK projelerinde Lemmatized CBOW mimarisi optimum seçimdir.

Gelecek Çalışmalar İçin Öneriler: Word2Vec modelleri statik gömme sınırlılığı nedeniyle kelimelerin cümle içindeki sırasını ve dinamik bağlamını tam olarak yakalayamamaktadır. Projenin bir sonraki aşamasında, kelimelere cümle içindeki konumuna göre dinamik ağırlıklar atayabilen Transformer tabanlı güncel dil modellerinin (BERT, RoBERTa vb.) entegre edilmesi önerilmektedir.