

WORD2VEC TABANLI METİN BENZERLİĞİ VE PERFORMANS DEĞERLENDİRME RAPORU

Emre Yılmaz/Hüseyin kurulur

Github: <https://github.com/emre93004-code/Final-proje/tree/main>

1. GİRİŞ

Ödevin Amacı

Bu çalışmanın temel amacı, Doğal Dil İşleme (NLP) yöntemleri ve Kelime Gömme (Word Embedding) teknikleri yardımıyla İnsan Kaynakları (İK) alanındaki **"CV-İlan Eşleşmesi"** problemini simüle etmek ve çözmektir. Proje kapsamında, bir iş ilanını temsil eden örnek bir anahtar girdi metni ile veri setinde yer alan aday özgeçmişleri (dokümanlar) arasındaki anlamsal benzerlik Word2Vec mimarisi üzerinden hesaplanmıştır. 16 farklı model varyasyonu eğitilerek; veri ön işleme yöntemlerinin, kelime vektör boyutlarının, pencere genişliklerinin ve derin öğrenme mimarilerinin doküman sıralama ile kelime anlambilimi üzerindeki etkileri kapsamlı bir şekilde analiz edilmiştir.

Veri Seti Yapısı ve Ön İşleme Değerlendirmesi

- **Ham Veri (Raw Data):** Kaynak veri seti, adayların serbest metin formatında yazdığı, yapısal düzensizliğe sahip, stop-words (and, or, the vb.) içeren ve yüksek boyutlu bir İK veri yığınıdır.
- **Lemmatized Veri Seti (lemmatized.csv):** Kelimelerin morfolojik analiz yapılarak sözlükteki yalın anlam köklerine indirgendiği yapıdır (Örn: *managing, coordination, planning* → *manage, coordinate, plan*). İK terminolojisinin kurumsal bağlamı ve kelime bütünlüğü bu sayede korunmuştur.
- **Stemmed Veri Seti (stemmed.csv):** Kelimelerin sondaki eklerinin belirli katı kurallarla kırıldığı yapıdır (Örn: *management, manager* → *manag*). Bu işlem sözlük hacmini küçültse de, profesyonel terimlerde ciddi anlamsal bozulmalara ve dilbilgisel gürültüye (noise) yol açmıştır.

Proje Deposu ve Model Erişim Bilgileri

- **GitHub Çalışma Deposu:** [https://github.com/\[Kullanici_Adiniz\]/CV-Job-Matching-NLP](https://github.com/[Kullanici_Adiniz]/CV-Job-Matching-NLP) (Tüm veri temizleme, model eğitim ve test betikleri kaynak kod olarak eklenmiştir.)
- **Modeller ve Veri Seti Erişim Linki (Google Drive):** [https://drive.google.com/drive/folders/\[Drive_ID_Uzantiniz\]](https://drive.google.com/drive/folders/[Drive_ID_Uzantiniz]) (Eğitilen 16 adet .model uzantılı dosya ile ön işlenmiş CSV dosyaları dışarıdan erişime açık şekilde bulutta saklanmaktadır.)

2. YÖNTEM

Vektörleştirme Detayları ve Model Parametreleri

Projede, kelimelerin çok boyutlu bir vektör uzayında temsil edilmesi amacıyla **Gensim** kütüphanesi üzerinden **Word2Vec** algoritması kullanılmıştır. Model eğitimi esnasında 4 farklı hiperparametre varyasyonu kombine edilerek toplam **16 farklı model** ayağa kaldırılmıştır:

1. **Ön İşleme (Preprocessing):** Lemmatized vs. Stemmed
2. **Mimari (Architecture):** CBOW (Continuous Bag-of-Words) ve Skip-Gram

3. **Pencere Geniřlięi (Window Size):** 2 ve 4

4. **Vektör Boyutu (Vector Size / Dimension):** 100 ve 300

Benzerlik Hesaplaması ve Savunma Mekanizması

Sistemin döküman getirme performansını test etmek amacıyla, kurumsal yönetim yetkinliklerini temsil eden řu **Giriř Metni** girdi olarak verilmiřtir:

"Experience in business development, team management and strategy planning for corporate projects."

Sistemimizin kararlılıęını (**robustness**) korumak adına, veri ön iřleme süreçlerinde elenen veya model sözlüğünde yer almayan kelimelerin oluřturabileceęi ZeroDivisionError veya NaN hatalarına karřı bir savunma mekanizması entegre edilmiřtir. Eęer bir doküman veya sorgu tamamen bilinmeyen kelimelerden oluřuyorsa, sisteme dinamik olarak ilgili modelin boyutuna uygun bir **Sıfır Vektörü (Zero Vector)** atanmaktadır. Bu sayede sistem matematiksel olarak güvenli alanda tutulmuř ve alıřma esnasında ökmesi engellenmiřtir.

Giriř metni vektörü (\$A\$) ile doküman vektörü (\$B\$) arasındaki anlamsal benzerlik řu **Kosinüs Benzerlięi (Cosine Similarity)** formülüyle hesaplanmıřtır:

$$\text{Cosine Similarity} = \frac{A \cdot B}{|A| \cdot |B|}$$

3. SONULAR VE DEęERLENDİRME

(1) Cosine Deęerlendirme (Objective Evaluation) Tablosu

Sistem tarafından üretilen nesnel kosinüs benzerlik matrisi, modellerin getirdięi ilk 5 dokümanın skorlarını ve aritmetik ortalamalarını içermektedir:

Model Adı	Skor 1	Skor 2	Skor 3	Skor 4	Skor 5	Ortalama Skor
word2vec_lemmatized_cbow_win2_dim100.model	0.9762	0.9640	0.9594	0.9589	0.9579	0.9633
word2vec_lemmatized_cbow_win2_dim300.model	0.9759	0.9635	0.9595	0.9586	0.9579	0.9631
word2vec_lemmatized_cbow_win4_dim100.model	0.9682	0.9528	0.9505	0.9499	0.9481	0.9539
word2vec_lemmatized_cbow_win4_dim300.model	0.9722	0.9549	0.9541	0.9535	0.9526	0.9575

Model Adı	Sko r 1	Sko r 2	Sko r 3	Sko r 4	Sko r 5	Ortal ama Skor
word2vec_lemmatized_skipgram_ win2_dim100.model	0.96 27	0.95 67	0.95 42	0.95 39	0.95 18	0.955 9
word2vec_lemmatized_skipgram_ win2_dim300.model	0.96 29	0.96 03	0.95 86	0.95 53	0.95 36	0.958 1
word2vec_lemmatized_skipgram_ win4_dim100.model	0.95 72	0.95 69	0.95 60	0.95 45	0.95 00	0.954 9
word2vec_lemmatized_skipgram_ win4_dim300.model	0.95 53	0.95 47	0.95 41	0.94 84	0.94 82	0.952 1
word2vec_stemmed_cbow_win2_d im100.model	0.89 93	0.89 66	0.88 58	0.88 42	0.88 29	0.889 8
word2vec_stemmed_cbow_win2_d im300.model	0.89 80	0.89 73	0.88 74	0.88 58	0.88 56	0.890 8
word2vec_stemmed_cbow_win4_d im100.model	0.87 77	0.86 99	0.86 08	0.85 55	0.85 39	0.863 6
word2vec_stemmed_cbow_win4_d im300.model	0.89 57	0.89 02	0.88 67	0.88 15	0.88 00	0.886 8
word2vec_stemmed_skipgram_win 2_dim100.model	0.94 35	0.94 27	0.94 24	0.94 19	0.94 11	0.942 3
word2vec_stemmed_skipgram_win 2_dim300.model	0.93 80	0.93 70	0.93 50	0.93 36	0.93 31	0.935 3
word2vec_stemmed_skipgram_win 4_dim100.model	0.94 87	0.94 71	0.94 56	0.94 49	0.94 48	0.946 2
word2vec_stemmed_skipgram_win 4_dim300.model	0.94 88	0.94 67	0.94 62	0.94 56	0.94 53	0.946 5

(2) Anlamsal Değerlendirme (Subjective Evaluation) ve Kelime Analizi

Modellerin kalitesini ölçmek amacıyla, İK ilanlarının kalbi sayılan '**management**' anahtar kelimesine her modelin ürettiği en yakın (vektörel olarak en benzer) kelimeler incelenmiştir:

Kelime Benzerliği Çıktıları:

- **Lemmatized Modellerinin Yakın Terimleri:**
 - lemmatized_cbow_win2_dim100: *managing* (0.8483), *coordination* (0.8303), *operational* (0.8236) $\rightarrow$ **Yüksek Anlamsal Başarı.**
 - lemmatized_cbow_win4_dim300: *managing* (0.8757), *organizational* (0.8507), *coordination* (0.8500), *project* (0.8466) $\rightarrow$ **En Başarılı Model.**
- **Stemmed Modellerinin Yakın Terimleri:**
 - stemmed_skipgram_win2_dim100: *lush* (0.9767), *freshest* (0.9733), *hospic* (0.9731) $\rightarrow$ **Başarısız/Gürültülü Bağlam.**
 - stemmed_cbow_win2_dim300: *relax* (0.9531), *stuff* (0.9524), *charm* (0.9413) $\rightarrow$ **Anlamsal Kopukluk.**

Bulguların Yorumlanması:

Elde edilen sonuçlara baktığımızda, **lemmatized modellerinin** İK bağlamını (yöneticilik, koordinasyon, planlama) çok daha iyi kavradığını, **stemmed modellerinin** ise kelime kırpmaları nedeniyle anlam kaymaları yaşadığını net bir şekilde görüyoruz.

Görsel haritada ve çıktılarda fark edileceği üzere, lemmatized modelleri **0.75 - 0.88** aralığında matematiksel olarak daha stabil ve bağlamsal açıdan anlamlı skorlar verirken; stemmed modelleri bazı durumlarda **0.95+** gibi çok yüksek kosinüs skorlarına ulaşmaktadır. Ancak bu yüksek skorlar, '*lush*', '*relax*', '*stuff*' gibi İK sektörüyle ve *management* kelimesiyle uzaktan yakından ilgisi olmayan sonuçlardan kaynaklanmaktadır. Bu durum veri setinde bir "**anlamsal gürültüye**" (**semantic noise**) işaret etmektedir. Dilbilgisel köklerin korunması, profesyonel İK metinlerinin analizi için kritiktir. Bu bağlamda, lemmatized_cbow_win4_dim300.model kavramsal derinliği ile projenin **en başarılı modeli** seçilmiştir.


(3) Sıralama Tutarlılığı Değerlendirmesi (Ranking Agreement)

Modellerin getirdiği ilk 5 dokümanın (CV adaylarının) indeks bazlı örtüşmesini ölçen 16x16'lık Jaccard Benzerlik Matrisi çıkarılmış ve aşağıda seaborn kütüphanesiyle görselleştirilmiştir:

Sıralama Tutarlılığı Isı Haritası (Jaccard Heatmap)

Eklenen ısı haritası incelendiğinde, projenin mimari çıktıları hakkında şu kritik çıkarımlara ulaşılmaktadır:

16 Model Arası Sıralama Tutarlılığı (Jaccard Benzerlik Heatmap)



Ön İşleme Bloklaşması (En Kritik Çıkarım): Isı haritasında net mavi ve kırmızı kareleşmeler (bloklar) gözlemlenmektedir. Lemmatized modeller kendi aralarında kümelenerek yüksek tutarlılık sergilerken, stemmed modellerle karşılaştırıldıklarında Jaccard benzerlik skoru sıfıra yakın değerlere düşmektedir. Bu durum, veri ön işlemenin (Lemmatization vs Stemming) doküman sıralama başarısını belirleyen **en baskın faktör** olduğunu kanıtlar.

- **Tam Örtüşme (Jaccard = 1.00):** lemmatized_cbow_win2_dim100 ile lemmatized_cbow_win4_dim100 ve win2_dim300 modelleri arasında **1.00 tam benzerlik** tespit edilmiştir. Bu bulgu, modellerin pencere boyutu veya vektör boyutundan bağımsız olarak, döküman uzayındaki en optimize ilk 5 adayı (Örn: *Doc 117, 91, 311, 32, 420*) tamamen aynı sırada yakaladığını, yani model varyasyonunun kararlı (**robust**) kaldığını gösterir.
- **Mimari Etkisi (CBOW vs. Skip-Gram):** Aynı ön işleme türüne sahip CBOW ve Skip-Gram modelleri birbirleriyle **0.67** oranında ortak döküman (5 dökümandan 3 ortak döküman) getirmiştir. CBOW mimarisi dar ve odaklı kelime kümelerinde çevre kelimelerin ortalamasını hedeflediğinden, genel kurumsal İK kelime eşleşmelerini daha stabil tutmuş ve kosinüs ortalamalarında (0.963) Skip-Gram'a kıyasla daha kararlı bir başarı sunmuştur.

- **Hiperparametre Etkileri:** Vektör boyutunun 100'den 300'e çıkarılması veya pencere genişliğinin (window) 2'den 4'e yükseltilmesi, ilk 5 dökümanın tespit edilmesinde radikal bir sapma yaratmamış; model ana karakteristiğini korumuştur.