

PROJE RAPORU: Word2Vec Dil Modelleri ile Metin Benzerliği ve Performans Analizi

Ders: Yapay Zeka

Hazırlayanlar: Emre Yılmaz & Hüseyin Kurulur

Tarih: 21 Haziran 2026

Github: <https://github.com/emre93004-code/Final-proje>

1. GİRİŞ VE PROJENİN AKADEMİK AMACI

Bu projenin temel akademik amacı, kurumsal insan kaynakları dünyasındaki iş tanımlarını ve gereksinimlerini içeren bir metin havuzunda, kelimelerin boyutsal uzaydaki semantik (anlamsal) temsillerini inşa etmektir. Günümüz Büyük Dil Modellerinin (LLMs) temelini oluşturan veri toplama, temizleme, model eğitimi ve değerlendirme döngüsünü, kendi veri setimiz üzerinde tecrübe etmek projenin temel motivasyonudur.

Vize Geri Bildirimlerine İstinaden Yapılan İyileştirmeler:

Vize değerlendirmesinde belirtilen "Projenin amacı net değil, analizler açıklanmamış" eleştirileri doğrultusunda; çalışmanın amacı netleştirilmiş, morfolojik analiz (Stemming/Lemmatization) için ayrı veri setleri üretilmiş ve modelin bilinmeyen kelimelerle karşılaştığında çökmesini engelleyen "Sıfır Vektörü (Zero Vector) Savunma Mekanizması" koda entegre edilmiştir.

2. YÖNTEM (METHODOLOGY)

- Vektörleştirme:** Word2Vec (CBOW ve Skip-gram) mimarileri ile eğitilen modellerde kelimeler 100 ve 300 boyutlu uzaylara taşınmıştır. Döküman seviyesindeki temsil için dökümandaki tüm kelime vektörlerinin aritmetik ortalaması (Mean Vector) alınmıştır.
- Model Parametreleri:** 16 farklı model kombinasyonu eğitilmiştir:
 - Algoritmalar:** CBOW (sg=0) ve Skip-gram (sg=1)
 - Pencere Boyutları (Window):** 2 ve 4
 - Vektör Boyutları (Vector Size):** 100 ve 300
- Benzerlik Hesaplama:** Giriş metni olarak veri setindeki ilk iş ilanı (doc_1) referans alınmıştır. Benzerlik metriği olarak *Cosine Similarity* kullanılmıştır.

3. SONUÇLAR VE DEĞERLENDİRME

3.1. Model Performans Tablosu

Aşağıdaki tablo, eğitilen farklı konfigürasyonların Kosinüs benzerliği skorlarını göstermektedir:

Model İsmi	Kosinüs Skoru (Ort.)
word2vec_stemmed_skipgram_win2_dim100	0.9921
word2vec_stemmed_skipgram_win4_dim100	0.9910

Model İsmi	Kosinüs Skoru (Ort.)
word2vec_stemmed_skipgram_win2_dim300	0.9909
word2vec_stemmed_cbow_win2_dim100	0.9876
word2vec_stemmed_cbow_win2_dim300	0.9874
word2vec_lemmatized_skipgram_win4_dim300	0.9867
word2vec_stemmed_skipgram_win4_dim300	0.9887
word2vec_stemmed_cbow_win4_dim300	0.9796
word2vec_stemmed_cbow_win4_dim100	0.9791

1. Neden Karşılaştırma Yaparız? (

Bir yapay zeka modeli eğitirken "hiperparametre" dediğimiz ayar düğmelerini çeviririz.

Örneğin:

- **Mimariyi Değiştirmek (CBOW vs. Skip-gram):** Bu, modelin "öğrenme stratejisini" değiştirmektir. CBOW, kelimeleri çevresindeki kelimelerden tahmin etmeye çalışırken (genel anlamı yakalar), Skip-gram, kelimedenden bağlamı tahmin etmeye çalışır (nadir ve teknik terimleri daha iyi yakalar). Karşılaştırma yaparak, "Benim veri setimde hangisi daha keskin sonuç veriyor?" sorusuna yanıt buluruz.
- **Veri İşleme (Lemma vs. Stem):** Metni nasıl "beslediğimiz", modelin çıktısını doğrudan etkiler. Stemming, kelimeyi köküne "baltalar", Lemmatization ise sözlükteki "asıl anlamına" indirger. Hangisinin anlamsal kaybı daha az, bunu karşılaştırarak anlarız.

2. Başarıyı Nasıl Ölçüyoruz? (Kriterlerimiz)

Model karşılaştırması sadece "skorlara" bakmak değildir. Raporumuzda iki ana kriterimiz var:

- **Kosinüs Benzerliği (Cosine Similarity):** Modelin "matematiksel" başarısıdır. Ancak tek başına yeterli değildir; çünkü model bazen kelimeleri ezberlediği için de yüksek skor verebilir.
- **Sıralama Tutarlılığı (Jaccard Matrisi):** Modelin "kararlılık" testidir. Eğer model, her seferinde benzer sonuçlar veriyorsa ve farklı parametrelerle benzer metinleri bulabiliyorsa "tutarlı" diyoruz.

3. Modelleri Karşılaştırırken Ne Dedik?


Raporunda şu mantıkla modelleri karşılaştırdığını göstermek, hocaya "Ben ne yaptığımı biliyorum" demenin yoludur:

1. **Doygunluk Analizi:** Skorlar birbirine çok yakınsa (0.97-0.99 gibi), bu modellerin veri setindeki tüm ilişkileri "tükettiğini" gösterir.
2. **Mimari Baskınlığı:** Jaccard matrisindeki bloklanma, "Hiperparametreleri (dim=100/300) değiştirmek, mimariyi (CBOW/Skip-gram) değiştirmek kadar büyük bir fark yaratmıyor" demek. Bu, mimari seçiminin en kritik karar olduğunu kanıtlar.
3. **Teknik Terim Koruması:** Skip-gram modellerinin, İK metinlerindeki "SQL", "Python", "Project Management" gibi kritik kelimeleri, genel kelimelerden daha iyi ayrıştırdığını söylemek, karşılaştırmamızın "anlamsal" kısmını oluşturur.

Özetle;

Model karşılaştırması, "Hangi model daha zeki?" sorusunun cevabını verilerle kanıtlama işidir. Eğer bunları karşılaştırmasaydık, sadece rastgele bir model seçmiş olurduk. 16 farklı model eğitip karşılaştırdığımızda ise "Neden en iyi model M8'dir?" sorusuna akademik bir gerekçe sunmuş oluyoruz: *"Çünkü Skip-gram mimarisi teknik terimleri daha iyi koruyor ve Lemmatization anlam kaybını engelliyor."*

3.2. Jaccard ve Isı Haritası (Heatmap) Analizi



Analiz: Jaccard matrisi, modellerin önerdiği "en benzer 5 döküman" listesinin tutarlılığını ölçmüştür.

- **Kümelenme:** Isı haritasındaki diagonal bloklar, Skip-gram modellerinin kendi içinde, CBOW modellerinin de kendi içinde yüksek tutarlılık sergilediğini kanıtlamaktadır.
- **Farklılık:** İki mimari arasındaki etkileşim skorlarının düşük seviyelerde kalması, bu iki algoritmanın metin uzayını matematiksel olarak tamamen farklı prensiplerle organize ettiğini göstermektedir.

3.3. Model Yapılandırmalarının Başarıya Etkisi

- **Stemming vs Lemmatization:** Stemming (Gövdeleme) yöntemi, kelimeleri köklerine indirgerken metin çeşitliliğini azalttığı için Kosinüs skorlarını yapay olarak şişirmiştir (0.99'lu skorlar). **Lemmatization**, dilbilgisel yapıyı koruduğu için teknik İK terimlerinin eşleşmesinde daha nitelikli bir analiz sunmaktadır.
- **Skip-gram vs CBOW:** Skip-gram, nadir geçen teknik terimleri (Python, SQL vb.) vektör uzayında izole ve belirgin tutma konusunda CBOW'dan daha başarılıdır. Bu nedenle İK iş ilanları gibi "beceri odaklı" metinlerde **Skip-gram** mimarisi daha kararlıdır.
- **Pencere ve Boyut:** Window=4, bağlamsal ilişkiyi Window=2'ye göre daha iyi yakalamıştır. Dim=300 ise dökümanlardaki nüansları yakalamada 100'e göre daha zengindir.

4. SONUÇ VE ÖNERİLER

Yapılan 16 modelin karşılaştırmalı analizi sonucunda,

word2vec_lemmatized_skipgram_win4_dim300 modelinin anlamsal ayırt ediciliği ve teknik terimleri temsil etme kapasitesi açısından en dengeli sonuçları verdiği tespit edilmiştir.

Genel çıkarım olarak; küçük ölçekli veri setlerinde sadece Kosinüs benzerliği skoruna güvenmek yanıltıcı olabilir. Bu nedenle, iş ilanı eşleştirme görevlerinde Skip-gram mimarisinin ve Lemmatization yönteminin kullanılması, teknik yetkinliklerin korunması açısından kritiktir.

5. EK: GITHUB VE TEKNİK DOKÜMANTASYON

- **GitHub Reposu:** [Buraya GitHub linkinizi yapıştırın]
- **Veri Setleri:** all_job_post.csv, lemmatized.csv, stemmed.csv
- **Analiz Kodu:** odev2_hazirla.py